

# Modelos de precios y backtesting

---

Gabriel Vergara Schifferli

19 Octubre 2021

Modelos de precios para considerar en estructura dinámica en el sistema de control aplicado a la gestión de riesgo.

- Modelos de series de tiempo
  - Procesos de memoria larga
  - Modelo de volatilidad estocástica
  - Markov-Switching GARCH
  - Modelos de mezclas de distribución
- Backtesting en métricas de riesgo
  - Test para Value at Risk
  - Test para Expected Shortfall y VaR conjunto
  - Expectiles\*
- Comparación de modelos: *Model Confidence Set*

Considerando la serie de precios logarítmica  $p_t = \ln(P_t)$   
y el operador de rezago  $B : B(p_t) = p_{t-1}$ ,  $B^n(p_t) = p_{t-n}$

## ARMA(p,q)

considerando el proceso  $\{p_t\}$

$$p_t - \phi_1 p_{t-1} - \cdots - \phi_p p_{t-p} = \varepsilon_t + \theta_1 \varepsilon_t + \cdots + \theta_q \varepsilon_{t-q},$$

donde  $\varepsilon \sim WN(0, \sigma^2)$ .

Considerando

$$\Phi(B) = (1 - \phi_1 B - \cdots - \phi_p B^p)$$

$$\Theta(B) = (1 + \theta_1 B + \cdots + \theta_q B^q)$$

Se escribe de forma compacta el proceso ARMA(p,q)

$$\Phi(B)p_t = \Theta(B)\varepsilon_t$$

Considerando el operador de diferenciación:

$$\nabla x_t = x_t - x_{t-1} \implies \nabla^k x_t = \nabla(\nabla^{k-1} x_{t-1})$$

$$\nabla^k = (1 - B)^k = \sum_{j=1}^k \binom{n}{k} B^k$$

## ARIMA(p,d,q)

el proceso  $p_t$  sigue un modelo ARIMA(p,d,q) si el proceso diferenciado

$\nabla^d p_t \sim \text{ARMA}(p, q)$

$$\Phi(B)\nabla^d p_t = \Theta(B)\varepsilon_t$$

Son procesos de memoria larga, donde  $\gamma(h) = \text{cov}(p_t, p_{t+h})$  no es absolutamente sumable.

Otra definición: que tiene un decaimiento hiperbólico de la autocovarianza :  $\gamma(h) \sim h^{2d-1} \ell_1(h)$  según  $h \rightarrow \infty$ , con  $d$  el parámetro de memoria larga y  $\ell(\cdot)$  una función de variación lenta.

## ARFIMA(p,d,q)

un proceso  $p_t$  sigue un modelo ARFIMA si:

$$\Phi(B)p_t = \Theta(B)\nabla^{-d}\varepsilon_t$$

donde  $\Phi$  y  $\Theta$  no tienen raíces comunes y  $\nabla^{-d}$  es un operador de diferenciación fraccionario:

$$\nabla^{-d} = \sum_{j \geq 0} \eta_j B^j = \eta(B)$$

con

$$\eta_j = \frac{\Gamma(j+d)}{\Gamma(j+1)\Gamma(d)},$$

para  $0 < d < 0.5$ , y  $\varepsilon_t \sim WN(0, \sigma^2)$

### EGARCH (Nelson (1991))

*exponential GARCH*

$$\ln(\sigma_t^2) = w + \sum_{i=1}^p \{\alpha_i (|\varepsilon_{t-i}| - E[|\varepsilon_{t-i}|]) + \gamma_i \varepsilon_{t-i}\} + \sum_{j=1}^q \beta_j \ln(\sigma_{t-j}^2)$$

### GJRARCH (Glosten et al. (1993))

$$\sigma_t^2 = w + \sum_{i=1}^p [\alpha_i + \gamma_i I_{\varepsilon_{t-i} > 0}] \varepsilon_{t-i}^2 + \sum_{j=1}^q \beta_j \sigma_{t-j}^2$$

### APARCH (Ding, Granger y Engle 1993)

*asymmetric power ARCH*

$$\sigma_t^\delta = \alpha_0 \sum_{i=1}^r \alpha_i (|\varepsilon_{t-i}| - \gamma_i \varepsilon_{t-i})^\delta + \sum_{j=1}^s \beta_j \sigma_{t-j}^\delta$$

### TGARCH (Zakoian (1994))

*Threshold GARCH*

$$\sigma_t^2 = w + \sum_{i=1}^p \alpha_i [(1 - \gamma_i) \varepsilon_{t-i}^+ + (1 + \gamma_i) \varepsilon_{t-i}^-] + \sum_{j=1}^q \beta_j \sigma_{t-j}^2$$

### RCAR

*random coefficient autoregressive model*

### CHARMA

*conditional heteroscedastic autorregressive moving average model*

### GARCH(1,1)-M

*garch in mean*

$$r_t = \mu + c\sigma_t^2 + a_t, \quad a_t = \sigma_t \varepsilon_t$$
$$\sigma_t^2 = \alpha_0 + \alpha_1 a_{t-1}^2 + \beta_1 \sigma_{t-1}^2$$

$c$  se le llama *risk premium parameter*, el retorno se relaciona positivamente con su volatilidad pasada.

### ZD-GARCH (Li, Zhang, Zhu and Ling (2018))

*Zero drift GRACH*

$$\sigma_t^2 = \alpha a_{t-1}^2 + \beta \sigma_{t-1}^2$$

- Extender la propiedad de memoria larga del ARFIMA a la volatilidad.

### FIGARCH(p,d,q)

$$\begin{aligned}a_t &= \sigma_t \varepsilon_t \\ \sigma_t^2 &= \omega + \beta(L)\sigma_t^2 + [1 - \beta(L) - [1 - \phi(L)](1 - L)^d]a_t^2\end{aligned}$$

donde  $L$  es el operador de rezago,  $\beta(L) = \sum_k^q \beta_k L^k$ ,  $\phi(L) = \sum_k^q \phi_k L^k$  y  $[1 - \beta(L)]$ ,  $[1 - \phi(L)]$  tienen raíces fuera del círculo unitario con  $(1 - L)^d$  el operador de diferenciación fraccionario para el parámetro de memoria larga  $0 < d < 1$ .



- Incorporar la propiedad de memoria larga a la volatilidad
- Considerar cambios en la dinámica de la volatilidad

### TV-FIGARCH

$$\begin{aligned}a_t &= \sigma_t \varepsilon_t \\ \sigma_t^2 &= \omega + \beta(L)\sigma_t^2 + [1 - \beta(L) - [1 - \phi(L)](1 - L)^d]a_t^2 + f_t \\ f_t &= \sum_{r=1}^R \omega_r F_r(s_t, \gamma_r, c_r)\end{aligned}$$

Donde  $F_r(s_t, \gamma_r, c_r)$  son funciones de transición determinadas por cambios de régimen.

Una elección apropiada para sería una función de transición logística

$$F_r(s_t, \gamma_r, c_r) = (1 + \exp\{-\gamma_r(s_t - c_r)\})^{-1}$$

con  $\gamma_r > 0$  parámetro que controla el grado de suavidad,  $c_r$  parámetro de umbral y  $s_t = t/T$  la variable de transición.

- Surge al introducir un término estocástico en la ecuación de volatilidad

## Stochastic Volatility

$$a_t = \sigma_t \varepsilon_t \quad \ln(\sigma_t^2) = \alpha_0 + \sum_i^m \alpha_i \ln(\sigma_{t-i}^2) + \nu_t$$

con  $\varepsilon_t \sim^{iid} N(0, 1)$ ,  $\nu_t \sim^{iid} N(0, \sigma_\nu^2)$ ,  $\nu_t \perp \varepsilon_t$

## Long memory stochastic volatility

$$a_t = \sigma_t \varepsilon_t, \quad \sigma_t = \sigma \exp(u_t/2), \quad (1 - L)^d u_t = \eta_t$$

$\sigma > 0$ ,  $\varepsilon_t \sim^{iid} N(0, 1)$ ,  $\eta_t \sim^{iid} N(0, \sigma_\eta^2)$ ,  $\varepsilon_t \perp \eta_t$ ,  $0 < d < 0.5$

GARCH con cambio estructural regido por una cadena de Markov no observable.

$$r_t | (S_t = k, \mathcal{F}_{t-1}) \sim F(0, \sigma_{k,t}^2, \theta_k)$$

con  $F(0, \sigma_{k,t}^2, \theta_k)$  distribución con media cero, varianza variando en el tiempo  $\sigma_{k,t}^2$  y parámetros  $\theta_k$


## MS-GARCH

$$\begin{aligned} a_t &= \sigma_t \epsilon_t \\ \sigma_t^2 &= \alpha_{0,s_t} + \sum_{i=1}^u \alpha_{i,s_t} a_{t-i}^2 + \sum_{j=1}^v \beta_{j,s_t} \sigma_{t-j}^2 \end{aligned}$$

done  $s_t$  es una cadena de Markov ergódica en un conjunto finito  $S = \{1, 2, \dots, n\}$  con una probabilidad de transición  $\{\eta_{ij} = \mathbf{P}(s_t = i | s_{t-1} = j)\}$  y una medida de probabilidad invariante  $\{\pi_i\}$ :

$$P(s_{t+1} = i | s_t = j, s_{t-1} = j_1, s_{t-2} = j_2 \dots) = P(s_{t+1} = i | s_t = j) = \eta_{ij}$$

- Se tienen  $n$  regímenes distintos
- Cada régimen tiene estructura distinta  
e.g. tGARCH-GARCH



$$r_t \sim DM(p_1, \dots, p_k; \mu_1, \dots, \mu_k; h_1, \dots, h_k)$$

Donde  $DM$  es una mezcla de densidades con la siguiente forma:

$$\vartheta(x) = \sum_i^k p_i f_i(x), \quad \sum_i p_i = 1, \quad f_i(x) = f(y; \mu_i; h_i)$$

con  $[p_1, \dots, p_k]$  la regla de mezcla de densidades.

Se puede ver como un modelo de Markov-Switching GARCH, en el cual las probabilidades de transición son independientes del estado anterior.

### K-GARCH(1,1)

Considerando mezclas de normales,

$$\begin{aligned} \sigma_{i,t}^2 &= w_i + \alpha_i \varepsilon_{t-1}^2 + \beta_i \sigma_{i,t-1}^2, \quad \forall i = 1, \dots, K \\ \sigma_t^2 &= \sum p_i \sigma_{i,t}^2 + \sum p_i \mu_i^2 \end{aligned}$$

$\Rightarrow$  se mezclan distintos tipos de garch, con distintas distribuciones  
e.g. *eGARCH-tGARCH-ged-std*

## Ejemplo modelo de precios

considerando  $r_t$  la serie de retornos logarítmicos

$$r_t \sim AR(2) - GARCH(1, 1)$$

$$r_t = \mu + \phi_1 r_{t-1} + \phi_2 r_{t-2} + a_t$$

$$a_t = \sigma_t \varepsilon_t$$

$$\sigma_t^2 = \alpha_0 + \alpha_1 \sigma_{t-1}^2 + \beta_1 a_{t-1}^2$$

$$\varepsilon_t \sim N(0, 1)$$

Entonces, los predictores quedan :

$$E(r_{t+1} | \mathcal{F}_{t-1}) = r_t(1) = \mu + \phi_1 r_t + \phi_2 r_{t-1}$$

$$E(\sigma_{t+1}^2 | \mathcal{F}_{t-1}) = \sigma_t^2(1) = \alpha_0 + \alpha_1 a_t^2 + \beta_1 \sigma_t^2$$

Luego,

$$\hat{r}_{t+1} \sim N(r_t(1), \sigma_t^2(1))$$

$\Rightarrow$  se tiene una estructura para estimar predictores de VaR y ES por ejemplo.

## Backtesting

*Para evaluar el desempeño de los modelos de riesgo, las medidas de riesgo proyectadas son comparadas con las pérdidas realizadas sobre un periodo de tiempo y su correcta especificación es testeada estadísticamente.*

### Value at Risk

Pérdida máxima esperada con una probabilidad  $\alpha$  sobre un periodo:

$$VaR_{\alpha}(X) = \inf\{x : F_X(x) \geq \alpha\} = F_X^{-1}(\alpha)$$

Para realizar un test sobre las predicciones de 1 paso sobre el VaR se construye una sucesión de aciertos para las violaciones del VaR:

$$\begin{aligned} I_{t+1} &= 1, & \text{si } r_{t+1} < VaR_{t+1}^{\alpha} \\ I_{t+1} &= 0, & \text{si } r_{t+1} > VaR_{t+1}^{\alpha} \end{aligned}$$

donde  $VaR_{t+1}^{\alpha}$  es el predictor del VaR para el tiempo  $t + 1$  a un nivel  $\alpha$ .

Bajo la hipótesis de una correcta especificación del modelo, la sucesión de aciertos debe ser independiente y seguir una distribución Bernoulli.

$$\begin{aligned} H_0 : I_{t+1} &\sim \text{Bernoulli}(\alpha), & (1) \\ f(I_{t+1}, p) &= (1 - p)^{1-I_{t+1}} p^{I_{t+1}} & (2) \end{aligned}$$



## Unconditional Coverage test (UC) Kupiec (1995)

### Objetivo:

Testear si la cantidad de retornos menores al  $VaR_\alpha$  predicho corresponde al nivel  $\alpha$  (*portion of failures POF*).

Para  $\{I_t\}_t$  anterior,

$$L(\pi) = \prod (1 - \pi)^{1-I_{t+1}} \pi^{I_{t+1}} = (1 - \pi)^{T_0} \pi^{T_1}$$

se tiene que

$$\hat{\pi}_{MLE} = \frac{T_1}{T_0 + T_1}$$

Bajo  $H_0 : \pi = \alpha$

$$LR_{uc} = -2 \ln \left[ \frac{L(\alpha)}{L(\hat{\pi})} \right] \sim \chi_1^2, \quad (3)$$

## Conditional Coverage test (CC) Christoffsen (1998)

### Objetivo:

Ver que la serie corresponde a la cantidad de aciertos y no se generan clusters de retornos menores al VaR predicho.

Considerando que  $\{I_t\}_t$  presenta una dependencia temporal y sigue una sucesión de Markov con matriz de probabilidad de transición:

$$\Pi_1 = \begin{pmatrix} 1 - \pi_{01} & \pi_{01} \\ 1 - \pi_{11} & \pi_{11} \end{pmatrix}, \quad (4)$$

donde  $\pi_{01}$  es la probabilidad de transición de 0 a 1, con verosimilitud:

$$L(\Pi_1) = (1 - \pi_{01})^{T_{00}} \pi_{01}^{T_{01}} (1 - \pi_{11})^{T_{10}} \pi_{11}^{T_{11}}, \quad (5)$$

Si la  $\{I_t\}_t$  es independiente del tiempo, se tiene que  $\pi_{01} = \pi_{11} = \pi$ , entonces:

$$\hat{\Pi}_{1_{MLE}} = \begin{pmatrix} 1 - \hat{\pi} & \hat{\pi} \\ 1 - \hat{\pi} & \hat{\pi} \end{pmatrix}, \quad LR_{cc} = -2 \ln \left[ \frac{L(\alpha)}{L(\hat{\Pi}_1)} \right] \sim \chi_1^2$$

### Objetivo:

Testear que no exista capacidad predictiva sobre las excepciones del VaR predicho.

Consideramos la sucesión  $Hit_t(\alpha) = I_t(\alpha) - \alpha$ , bajo la correcta especificación del modelo se tienen las condiciones de momentos:  $E[Hit_t(\alpha)] = 0$ ,  $E[Hit_t(\alpha)I_{t-1}] = 0$ ,  $E[Hit_t(\alpha)Hit_{t'}(\alpha)] = 0 \forall t \neq t'$  por lo tanto, se tiene el siguiente modelo de regresión:

$$Hit_t(\alpha) = \delta + \sum_{k=1}^K \beta_k Hit_{t-k}(\alpha) + \sum_{k=1}^K \gamma_k g[\mathcal{F}_{t-k}] + \varepsilon_t, \quad (6)$$

Entonces, bajo la hipótesis nula de la eficiencia condicional es equivalente a testear si los coeficientes son conjuntamente nulos:

$$H_0 : \delta = \beta_1 = \dots = \beta_K = \gamma_1 = \dots = \gamma_K = 0, \quad \forall k = 1, \dots, K \quad (7)$$

- VaR no es capaz de medir pérdidas más allá de un nivel  $\alpha$ .
- ES mide el riesgo de cola que no captura el VaR.

### Expected Shortfall

ES corresponde a la pérdida esperada dado que la pérdida excede el  $\alpha$ -cuantil del VaR:

$$ES_{\gamma}(X) = \frac{1}{\gamma} \int_0^{\gamma} VaR_{\alpha}(X) d\alpha \quad (8)$$

donde  $ES_{\gamma}(X)$  es el *Expected Shortfall* de la v.a.  $X$  a un nivel  $\gamma$ , esto es, dada una pérdida  $r$  se tiene que  $ES = E[r | r < VaR]$ .

### Objetivo:

Se testea si el valor esperado de ER es cero contra la hipótesis unilateral de que son mayores que cero, esto es, que el ES esta sistemáticamente siendo subestimado

Considerando

$$\left\{ R_{t+1} : t \in T, r_{t+1} < \hat{Va}R_{\alpha}^{t+1}, \quad R_{t+1} = \frac{r_{t+1} - \hat{ES}_{\alpha}^{t+1}}{\hat{\sigma}_{t+1}} \right\}$$

las excedencias de residual.

Bajo  $H_0$  se estima correctamente la dinámica de  $(\mu_{t+1} \text{ y } \sigma_{t+1})$  y el ES.

Por argumentos asintóticos de *Teoría de valores extremos (EVT)* estos residuos deberían comportarse como iid con media cero.

Aplicado a un par  $(VaR, ES)$  a un nivel  $\alpha$ , considerando la función de identificación estricta:

$$V(Y, \nu, e) = \begin{pmatrix} \alpha - \mathbb{1}_{\{Y \leq \nu\}} \\ e - \nu + \mathbb{1}_{\{Y \leq \nu\}}(\nu - Y)/\alpha \end{pmatrix}$$

donde  $E(V(Y, \nu, e)) = 0 \iff \nu$  y  $e$  son los verdaderos VaR y ES de  $Y$ .

Entonces se tienen los test:

$$H_0^{2s} : E(V(Y_t, \hat{\nu}_t, \hat{e}_t) | \mathcal{F}_{t-1}) = 0 \quad v/s \quad H_1^{2s} : E(V(Y_t, \hat{\nu}_t, \hat{e}_t) | \mathcal{F}_{t-1}) \neq 0$$

$$H_0^{1s} : E(V(Y_t, \hat{\nu}_t, \hat{e}_t) | \mathcal{F}_{t-1}) \geq 0 \quad v/s \quad H_1^{1s} : E(V(Y_t, \hat{\nu}_t, \hat{e}_t) | \mathcal{F}_{t-1}) < 0$$

con el estadístico tipo Wald

$$T_{CC} = T \left( \frac{1}{T} \sum_{t=1}^T \mathbf{h}_t V(Y_t, \hat{\nu}_t, \hat{e}_t) \right)^T \hat{\Delta}_T^{-1} \left( \frac{1}{T} \sum_{t=1}^T \mathbf{h}_t V(Y_t, \hat{\nu}_t, \hat{e}_t) \right) \sim \chi_q^2,$$

donde  $\hat{\Delta}_T^{-1} = \frac{1}{T} \sum_{t=1}^T (\mathbf{h}_t V(Y_t, \hat{\nu}_t, \hat{e}_t))(\mathbf{h}_t V(Y_t, \hat{\nu}_t, \hat{e}_t))^T$ .

## Objetivo:

Se testea conjuntamente (VaR, ES) la correcta especificación del modelo y en cierto sentido la volatilidad  $\sigma$ .

## *simple CC test*

Utiliza solamente los predictores de VaR y ES.

$$\mathbf{h}_t = I_2$$

para el test unilateral y bilateral.

## *general CC test*

Utiliza los predictores de VaR, ES y la volatilidad  $\hat{\sigma}_t$

$$\mathbf{h}_t = \hat{\sigma}_t((\hat{e}_t - \hat{v}_t)/\alpha, 1), \quad y \quad \mathbf{h}_t = \begin{pmatrix} 1 & |\hat{v}_t| & 0 & 0 \\ 0 & 0 & 1 & \hat{\sigma}_t^{-1} \end{pmatrix}$$

para el test unilateral y bilateral respectivamente.

### Objetivo:

Testear la correcta especificación del modelo en cuanto a los predictores del ES.

Considerando los retornos  $\{r_t, t = 1, \dots, T\}$  y la serie de predictores a 1 paso de ES  $\{\hat{e}_t, t = 1, \dots, T\}$  se tiene un esquema general de regresión de los retornos con el ES y un intercepto,

$$r_t = \gamma_1 + \gamma_2 \hat{e}_t + u_t^e,$$

donde  $ES_\alpha(u_t^e | \mathcal{F}_{t-1}) = 0$  c.t.p. o equivalentemente

$$ES_\alpha(r_t | \mathcal{F}_{t-1}) = \gamma_1 + \gamma_2 \hat{e}_t.$$

Considerando el test :

$$H_0 : (\gamma_1, \gamma_2) = (0, 1) \quad v/s \quad H_1 : (\gamma_1, \gamma_2) \neq (0, 1).$$

Bajo  $H_0$ , los predictores  $\hat{e}_t$  están correctamente especificados y se tiene que  $\hat{e}_t = ES_\alpha(r_t | \mathcal{F}_{t-1})$  c.t.p.



Considerando una formulación más general  $Y_t = W_t^T \gamma + u_t^e$ , estimar el parámetro  $\gamma$  no es posible pues no existe función de pérdida estrictamente consistente y funciones de identificación para el ES, pero sí se tiene conjuntamente para (VaR, ES).

Entonces, se consideran una regresión conjunta:

$$Y_t = V_t^T \beta + u_t^q, \quad Y_t = W_t^T \gamma + u_t^e,$$

donde  $V_t, W_t$  son  $\mathcal{F}_{t-1}$ -medibles, y  $VaR_\alpha(u_t^q | \mathcal{F}_{t-1}) = 0$  y  $ES_\alpha(u_t^e | \mathcal{F}_{t-1}) = 0$  c.t.p.

Por lo que se proponen los siguientes tests considerando ( $\hat{\nu} = VaR, \hat{e} = ES$ ):

## Auxiliary ESR

Se testea conjuntamente (*VaR*, *ES*), considerando  $V_t = (1, \hat{v}_t)$  y  $W_t = (1, \hat{e}_t)$ ,

$$r_t = \beta_1 + \beta_2 \hat{v}_t + u_t^q, \quad r_t = \gamma_1 + \gamma_2 \hat{e}_t + u_t^e,$$

$$H_0 : (\gamma_1, \gamma_2) = (0, 1) \quad v/s \quad H_1 : (\gamma_1, \gamma_2) \neq (0, 1)$$

## Strict ESR

Se testea solamente *ES*, considerando  $V_t = W_t = (1, \hat{e}_t)$ ,

$$r_t = \beta_1 + \beta_2 \hat{e}_t + u_t^q, \quad r_t = \gamma_1 + \gamma_2 \hat{e}_t + u_t^e,$$

$$H_0 : (\gamma_1, \gamma_2) = (0, 1) \quad v/s \quad H_1 : (\gamma_1, \gamma_2) \neq (0, 1)$$

## Intercept ESR

Se testea solamente *ES*, considerando el error de predicción  $r_t - \hat{e}_t$

$$r_t - \hat{e}_t = \beta_1 + u_t^q, \quad r_t - \hat{e}_t = \gamma_1 + u_t^e,$$

$$H_0^{2s} : \gamma_1 = 0 \quad v/s \quad H_1^{2s} : \gamma_1 \neq 0$$

$$H_0^{1s} : \gamma_1 \geq 0 \quad v/s \quad H_1^{1s} : \gamma_1 < 0$$

Otra métrica de riesgo con buenas propiedades estadísticas y similar información al ES.

$\tau$ -expectile  $e_\tau(X)$  de  $X$  con media finita, es la única solución  $x = e_\tau(X)$  de la ecuación

$$\tau \int_x^\infty (y - x) dF_X(y) = (1 - \tau) \int_{-\infty}^x (x - y) dF_X(y)$$

es una medida de riesgo obtenible y coherente para  $\tau \in [1/2, 1)$ , es una generalización de la esperanza.

Un artículo sobre métricas de riesgo, en cuanto a obtenibilidad y coherencia entre otras propiedades de las medidas VaR, ES y Expectiles:



Chen, J.M. (2018).

**On Exactitude in Financial Regulation: Value-at-Risk, Expected Shortfall, and Expectiles.**

*Risks* 2018, 6, 61. <https://doi.org/10.3390/risks6020061>.

- Test anteriores no proporciona comparación entre modelos.
- Se busca construir un conjunto de modelos superiores que tienen misma capacidad predictiva.

### Objetivo:

Determinar los modelos que tienen la misma capacidad predictiva dado una función de pérdida.

Se define la variable de rendimiento considerando la función de pérdida

$$L_{i,t} = L(Y_t, \hat{Y}_{i,t}):$$

$$d_{ij,t} = L_{i,t} - L_{j,t} \quad \forall i, j \in M^0$$

El estadístico de pérdida relativa muestral:

$$\bar{d}_{ij} = \frac{1}{n} \sum_{t=1}^n d_{ij,t}, \quad \bar{d}_i = \frac{1}{m} \sum_{j \in M} \bar{d}_{ij}$$

Asumiendo que  $\mu_{ij} = E(d_{ij,t}) < \infty$  e invariante en  $t \forall i, j \in \mathcal{M}^0$  se rankean en términos de la pérdida esperada, donde el modelo  $i$  es preferido al  $j$  si  $\mu_{ij} < 0$

### Set of superior models (SSM)

$$\mathcal{M}^* := \{i \in \mathcal{M}^0 : \mu_{ij} \leq 0 \forall j \in \mathcal{M}^0\}$$

Entonces, se busca determinar el conjunto  $\mathcal{M}^*$  mediante una secuencia de tests de significancia, donde los conjuntos que son significativamente inferior a los demás elementos de  $\mathcal{M}^0$  son eliminados. Esto es,

### Equal predictive ability test (EPA)

$$H_{0,\mathcal{M}} : \mu_{ij} = 0 \forall i, j \in \mathcal{M} \quad v/s \quad \mu_{ij} \neq 0$$

donde  $\mathcal{M} \subset \mathcal{M}^0$ , y el caso análogo para  $\mu_i$

Luego se derivan los estadísticos  $t$

$$t_{ij} = \frac{\bar{d}_{ij}}{\sqrt{\hat{\text{var}}(\bar{d}_{ij})}}, \quad t_i = \frac{\bar{d}_i}{\sqrt{\hat{\text{var}}(\bar{d}_i)}} \text{ para } i, j \in \mathcal{M}.$$

y las hipótesis EPA se resumen en los estadísticos de prueba:

$$T_{R,\mathcal{M}} = \max_{i,j \in \mathcal{M}} |t_{ij}|, \quad T_{\max,\mathcal{M}} = \max_{i \in \mathcal{M}} t_i$$

con una regla de eliminación

$$e_{R,\mathcal{M}} = \arg \max_i \left\{ \sup_{j \in \mathcal{M}} \frac{\bar{d}_{ij}}{\sqrt{\hat{\text{var}}(\bar{d}_{ij})}} \right\}, \quad e_{\max,\mathcal{M}} = \arg \max_{i \in \mathcal{M}} \frac{\bar{d}_i}{\sqrt{\hat{\text{var}}(\bar{d}_i)}}$$

### Algoritmo

1. iniciar  $\mathcal{M} = \mathcal{M}^0$ .
2. Testear para EPA, si EPA no es rechazada terminar y dejar  $\mathcal{M} = \mathcal{M}^*$ , en otro caso, eliminar el peor modelo mediante la regla de eliminación y volver al paso 1.

## Quantile Loss

$$QL_t^\alpha = (\alpha - I_t(\alpha))(r_t - VaR_t^\alpha)$$


## Bayer and Dimitriadis (2018)\*

De una familia más general (Fissler y Ziegel 2016), una forma particular:  
(funciones de scoring fuertemente consistentes para VaR y ES)

$$S(VaR_t^\alpha, ES_t^\alpha, r_t) = \frac{1}{-ES_t^\alpha} \left( ES_t^\alpha - VaR_t^\alpha + \frac{(VaR_t^\alpha - r_t)1_{\{r_t < VaR_t^\alpha\}}}{\alpha} \right) + \ln(-ES_t^\alpha)$$

Se consideraron precios de cierre de Bitcoin valorizados en USDT a una frecuencia de 1 hora durante 5 meses.

Datos descargados a través de *python-Binance* API.




**Figure 1:** Gráficos de precios de cierre y retornos logarítmicos con frecuencia horaria para el periodo establecido.



Estadísticas	Bitcoin
Cantidad de obs.	3599
Mínimo	-0.1195336
Q1	-0.0043263
Mediana	0.0002772
Media	-0.0000901
Q3	0.0047216
Máximo	0.0588610
Desv. std.	0.01003132
Asimetría	-1.027493
Curtosis	15.69013

(a) Tabla resumen de estadísticas.




(b) Histograma de retornos logarítmicos.

N°	model	UC	CC	DQ	ER	ESR	MCS
1	AR-tGARCH-sGARCH-std-norm	27,47%	17,21%	48,01%	23,10%	23,29%	100,00%
2	AR-gjrGARCH-tGARCH-std-norm	22,24%	13,14%	38,75%	15,50%	17,59%	100,00%
3	AR-eGARCH-gjrGARCH-std-std	42,16%	17,26%	29,65%	35,80%	33,36%	100,00%
4	AR-eGARCH-tGARCH-std-norm	34,76%	43,37%	28,44%	27,70%	21,66%	100,00%
5	AR-tGARCH-tGARCH-std-norm	17,21%	10,34%	44,64%	12,90%	14,57%	100,00%
6	AR-tGARCH-sGARCH-std-std	27,16%	13,43%	36,43%	24,60%	16,21%	100,00%
7	AR-eGARCH-tGARCH-std-std	34,76%	58,25%	28,57%	50,10%	42,63%	100,00%
8	AR-eGARCH-sGARCH-std-std	28,08%	50,08%	30,10%	42,80%	29,66%	100,00%
9	ARMA-eGARCH-tGARCH-norm-std	34,76%	58,25%	29,63%	25,10%	23,08%	100,00%
10	AR-tGARCH-tGARCH-norm-std	10,34%	10,34%	59,80%	11,40%	20,00%	100,00%
11	AR-eGARCH-tGARCH-norm-std	22,24%	34,76%	30,77%	18,90%	15,36%	100,00%
12	AR-tGARCH-gjrGARCH-std-std	21,76%	40,61%	27,24%	17,70%	13,57%	100,00%
13	AR-tGARCH-tGARCH-std-std	17,21%	13,43%	30,02%	19,90%	12,48%	100,00%
14	AR-gjrGARCH-eGARCH-norm-std	13,14%	35,56%	26,94%	33,80%	34,04%	100,00%
:	:	:	:	:	:	:	:

**Table 1:** Valores P para los procedimientos de backtesting y MCS utilizando la función de pérdida QL VaR. Se muestra el conjunto de modelos superiores con su especificación para la media y sus regímenes para la varianza (MS-GARCH).

Se probaron 2 especificaciones para media, 2 distribuciones y 4 modelos de varianza, en total 128 modelos de los cuales 89 fueron validados y 68 seleccionados en MCS a un 70%.



**Figure 3:** modelo AR-tGARCH-sGARCH-std-norm, excesos esperados 54, obtenidos 62 para VaR con  $\alpha = 0.05$  (Pvalue = 27.47%)

# Modelos de precios y backtesting

---

Gabriel Vergara Schifferli

19 Octubre 2021

Modelos de precios para considerar en estructura dinámica en el sistema de control aplicado a la gestión de riesgo.